

# Tema 4

## Síntese

### Geração de código e gestão de erros


*Compiladores, 2º semestre 2022-2023*

Miguel Oliveira e Silva, Artur Pereira, DETI, Universidade de Aveiro

## Conteúdo

|          |   |          |
|----------|---|----------|
| <b>1</b> | <b>Síntese: geração de código</b>             | <b>2</b> |
| 1.1      | Geração de código máquina . . . . .           | 2        |
| 1.2      | Geração de código . . . . .                   | 3        |
| <b>2</b> | <b><i>String Template</i></b>                 | <b>3</b> |
| 2.1      | Geração de código: padrões comuns . . . . .   | 6        |
| 2.2      | Geração de código para expressões . . . . .   | 6        |
| <b>3</b> | <b>Síntese: geração de código intermédio</b>  | <b>7</b> |
| 3.1      | Código de triplo endereço . . . . .           | 7        |
| 3.2      | TAC: Exemplo de expressões binárias . . . . . | 7        |
| 3.3      | TAC: Endereços e instruções . . . . .         | 7        |
| 3.4      | Controlo de fluxo . . . . .                   | 8        |
| 3.5      | Funções . . . . .                             | 8        |

# 1 Síntese: geração de código



- Podemos definir o objectivo de um compilador como sendo *traduzir* o código fonte de uma linguagem para outra linguagem.


source language → **Compiler** → target language

- A geração do código para a linguagem destino pode ser feita por diferentes fases (podendo incluir fases de optimização), mas nós iremos abordar apenas uma única fase.
- A estratégia geral consiste em identificar *padrões de geração de código*, e após a análise semântica percorrer novamente a árvore sintáctica (mas já com a garantia muito importante de inexistência de erros sintácticos e semânticos) gerando o código destino nos pontos apropriados.

## Exemplo: Calculadora

- Código fonte:

```
1+2*3:4
```



- Uma possível compilação para Java:

```
public class CodeGen {
    public static void main(String[] args) {
        int v2 = 1;
        int v5 = 2;
        int v6 = 3;
        int v4 = v5 * v6;
        int v7 = 4;
        int v3 = v4 / v7;
        int v1 = v2 + v3;
        System.out.println(v1);
    }
}
```


## 1.1 Geração de código máquina

- Tradicionalmente, o ensino de processadores de linguagens tende a dar primazia à geração de código baixo nível (linguagem máquina, ou *assembly*).

- A larga maioria da bibliografia mantém esse enfoque.
- No entanto, do ponto de vista prático serão poucos os programadores que, fazendo uso de ferramentas para gerar processadores de linguagens, necessitam ou ambicionam este tipo de geração de código.
- Nesta disciplina vamos, alternativamente, discutir a geração de código numa perspectiva mais abrangente, incluindo a geração de código em linguagens de alto nível.
- No que diz respeito à geração de código em linguagens de baixo nível, é necessário um conhecimento robusto em arquitectura de computadores e lidar com os seguintes aspectos:
  - Representação e formato da informação (formato para números inteiros, reais, estruturas, *array*, etc.);
  - Gestão e endereçamento de memória;
  - Implementação de funções (passagem de argumentos e resultado, suporte para recursividade com pilha de chamadas e *frame pointers*);
  - Alocação de registos do processador.
- (Consultar a bibliografia recomendada para estudar este tipo de geração de código.)

## 1.2 Geração de código

- Seja qual for o nível da linguagem destino, uma possível estratégia para resolver este problema consiste em identificar sem ambiguidade *padrões de geração de código* associados a cada *elemento gramatical da linguagem*.
- Para esse fim, é necessário definir o contexto de geração de código para cada elemento (por exemplo, geração de instruções na linguagem destino, ou atribuir a valor a uma variável), e depois garantir que o mesmo é compatível com todas as utilizações do elemento.



|  |  |
|--|--|
| $\begin{aligned} &\dots(e_1) \\ &v_1 = e_1 \\ &\dots(e_2) \\ &v_2 = e_2 \\ &v_+ = v_1 + v_2 \end{aligned}$ |  |
|--|--|

- Como a larguíssima maioria das linguagens destino são textuais, esses padrões de geração de código consistem em padrões de geração de texto.
- Assim sendo, em Java, poderíamos delegar esse problema no tipo de dados `String`, `StringBuilder`, ou mesmo na escrita directa de texto em em ficheiro (ou no *standard output*).
- No entanto, também aí o ambiente ANTLR4 fornece uma ajuda mais estruturada, sistemática e modular para lidar com esse problema.

## 2 String Template

- A biblioteca (Java) *String Template* fornece uma solução estruturada para a geração de código textual.
- O software e documentação podem ser encontrados em <http://www.stringtemplate.org>
- Para ser utilizada é apenas necessário o pacote `ST-4.?.jar` (a instalação feita do `antlr4` já incluiu este pacote).
- Vejamos um exemplo simples:

```
import org.stringtemplate.v4.*;
...
// code gen. pattern definition with <name> hole:
ST hello = new ST("Hello, <name>");
// hole pattern definition:
hello.add("name", "World");
```

```
// code generation (to standard output):
System.out.println(hello.render());
```

- Mesmo sendo um exemplo muito simples, podemos já verificar que a definição do padrão de texto, está separada do preenchimento dos “buracos” (atributos ou expressões) definidos, e da geração do texto final.
- Podemos assim delegar em partes diferentes do gerador de código, a definição dos padrões (que passam a pertencer ao contexto do elemento de código a gerar), o preenchimento dos “buracos” definidos, e a geração do texto final de código.
- Os padrões são blocos de texto e expressões.
- O texto corresponde a código destino literal, e as expressões são em “buracos” que podem ser preenchidos com o texto que se quiser.
- Sintaticamente, as expressões são identificadores delimitados por <expr> (ou por \$).

```
import org.stringtemplate.v4.*;
...
ST assign = new ST("<var> = <expr>;\n");
assign.add("var", "i");
assign.add("expr", "10");
String output = assign.render();
System.out.println(output);
```

### String Template Group

- Podemos também agrupar os padrões numa espécie de funções (módulo STGroup):

```
import org.stringtemplate.v4.*;
...
STGroup group = new STGroupString(
    "assign(var,expr) ::= \"<var> = <expr>;\n\"");
ST assign = group.getInstanceOf("assign");
assign.add("var", "i");
assign.add("expr", "10");
String output = assign.render();
System.out.println(output);
```

- Podemos também colocar cada função num ficheiro:

```
// file assign.st
assign(var,expr) ::= "<var> = <expr>;"
```

```
import org.stringtemplate.v4.*;
...
// assuming that assign.st is in current directory:
STGroup group = new STGroupDir(".");
ST assign = group.getInstanceOf("assign");
assign.add("var", "i");
assign.add("expr", "10");
String output = assign.render();
System.out.println(output);
```

- Uma melhor opção é optar por ficheiros modulares contendo grupos de funções/padrões:

```
// file templates.stg

templateName(arg1, arg2, ..., argN) ::= "single-line template"

templateName(arg1, arg2, ..., argN) ::= <<
multi-line template preserving indentation and newlines
>>

templateName(arg1, arg2, ..., argN) ::= <%
multi-line template that ignores indentation and newlines
%>
```

```
import org.stringtemplate.v4.*;
...
// assuming that templates.stg is in current directory:
STGroup allTemplates = new STGroupFile("templates.stg");
ST st = group.getInstanceOf("templateName");
...
```

## String Template: dicionários e condicionais

- Neste módulos podemos ainda definir dicionários (arrays associativos).

```
typeValue ::= [
    "integer": "int",
    "real": "double",
    "boolean": "boolean",
    default: "void"
]
```

- Na definição de padrões podemos utilizar uma instrução condicional que só aplica o padrão caso o atributo seja adicionado:

```
stats(stat) ::= <<
<if(stat)><stat; separator="\n"><endif>
>>
```

- O campo `separator` indica que em em cada operação `add` em `stat`, se irá utilizar esse separador (no caso, uma mudança de linha).

## String Template: Funções

- Podemos ainda definir padrões utilizando outros padrões (como se fossem funções).

```
module(name, stat) ::= <<
public class <name> {
    public static void main(String[] args) {
        <stats(stat)>
    }
}
>>

conditional(stat, var, stat_true, stat_false) ::= <<
<stats(stat)>
if (<var>) {
    <stat_true>
}<if(stat_false)>
else {
    <stat_false>
}<endif>
>>
```

## String Template: listas

- Também existe a possibilidade de utilizar listas para concatenar texto e argumentos de padrões:

```
binaryExpression(type, var, e1, op, e2) ::=
    "<decl(type, var, [e1, \" \", op, \" \", e2])>"
```

- ou:

```
binaryExpression(type, var, e1, op, e2) ::= <<
<decl(type, var, [e1, " ", op, " ", e2])>
>>
```

- Para mais informação sobre as possibilidades desta biblioteca devem consultar a documentação existente em: <http://www.stringtemplate.org>.

## 2.1 Geração de código: padrões comuns

- Uma geração de código modular requer um contexto uniforme que permita a inclusão de qualquer combinação de código a ser gerado.
- Na sua forma mais simples, o padrão comum pode ser simplesmente uma sequência de instruções.

```
stats (stat) ::= <<
< if (stat) > < stat ; separator = "\n" > < endif >
>>

module (name, stat) ::= <<
public class < name >
{
    public static void main (String [] args)
    {
        < stats (stat) >
    }
}
>>
```

- Com este padrão, podemos inserir no lugar do “buraco” `stat` a sequência de instruções que quisermos.
- Naturalmente, que para uma geração de código mais complexa podemos considerar a inclusão de buracos para membros de classe, múltiplas classes, ou mesmo vários ficheiros.
- Para a linguagem C, teríamos o seguinte padrão para um módulo de compilação:

```
stats (stat) ::= <<
< if (stat) > < stat ; separator = "\n" > < endif >
>>

module (name, stat) ::= <<
#include < stdio .h >
#include < math .h >

int main ()
{
    < stats (stat) >
}
>>
```

- Se a geração de código for guiada pela árvore sintáctica (como normalmente acontece), então os padrões de código a ser gerados devem ter em conta as definições gramaticais de cada símbolo, permitindo a sua aplicação modular em cada contexto.

## 2.2 Geração de código para expressões

- Para ilustrar a simplicidade e poder de abstração do *String Template* vamos estudar o problema de geração de código para expressões.
- Para resolver este problema de uma forma modular, podemos utilizar a seguinte estratégia:
  1. considerar que qualquer expressão tem a si associada uma variável (na linguagem destino) com o seu valor;
  2. para além dessa associação, podemos também associar a cada expressão um ST (`stats`) com as instruções que atribuem o valor adequado à variável.
- Como habitual, para fazer estas associações podemos definir atributos na gramática, fazer uso do resultados das funções de um *Visitor* ou utilizar a classe `ParseTreeProperty`
- Desta forma, podemos fácil e de uma forma modular, gerar código para qualquer tipo de expressão.
- Padrões para expressões (para Java) podem ser:

```
typeValue ::= [
    "integer": "int", "real": "double",
    "boolean": "boolean", default: "void"
]
```

```

init(value) ::= "<if(value)> = <value><endif>"
decl(type, var, value) ::=
    "<typeValue.(type)> <var><init(value)>;"

binaryExpression(type, var, e1, op, e2) ::=
    "<decl(type, var, [e1, \" \", op, \" \", e2])>"

```

- Para C apenas seria necessário mudar o padrão typeValue:

```

typeValue ::= [
    "integer": "int", "real": "double",
    "boolean": "int", default: "void"
]

```

## 3 Síntese: geração de código intermédio

### 3.1 Código de triplo endereço

- O padrão para expressões é um exemplo duma representação muito utilizada para geração de código baixo nível (em geral, intermédio, e não final), designada por *codificação de triplo endereço* (TAC).
- Esta designação tem origem nas instruções com a forma:  $x = y \text{ op } z$
- No entanto, para além desta operação típica de expressões binárias, esta codificação contém outras instruções (ex: operações unárias e de controlo de fluxo).
- No máximo, cada instrução tem três operandos (i.e. três variáveis ou endereços de memória).
- Tipicamente, cada instrução TAC realiza uma operação elementar (e já com alguma proximidade com as linguagens de baixo nível dos sistemas computacionais).

### 3.2 TAC: Exemplo de expressões binárias

- Por exemplo a expressão  $a + b * (c + d)$  pode ser transformada na sequência TAC:

```

t8 = d;
t7 = c;
t6 = t7 + t8;
t5 = t6;
t4 = b;
t3 = t4 * t5;
t2 = a;
t1 = t2 + t3;

```

- Esta sequência – embora fazendo uso desregrado no número de registos (o que, num compilador gerador de código máquina, é resolvido numa fase posterior de optimização) – é codificável em linguagens de baixo nível.

### 3.3 TAC: Endereços e instruções

- Nesta codificação, um endereço pode ser:
  - Um nome do código fonte (variável, ou endereço de memória);
  - Uma constante (i.e. um valor literal);
  - Um nome temporário (variável, ou endereço de memória), criado na decomposição TAC.
- As instruções típicas do TAC são:
  1. Atribuições de valor de operação binária:  $x = y \text{ op } z$
  2. Atribuições de valor de operação unária:  $x = \text{op } y$
  3. Instruções de cópia:  $x = y$
  4. Saltos incondicionais e etiquetas: **goto**  $L$  e **label**  $L$  :
  5. Saltos condicionais: **if**  $x$  **goto**  $L$  ou **ifFalse**  $x$  **goto**  $L$

6. Saltos condicionais com operador relacional: **if**  $x$  **relop**  $y$  **goto**  $L$  (o operador pode ser de igualdade ou ordem)
7. Invocações de procedimentos (**param**  $x_1 \dots$  **param**  $x_n$  ; **call**  $p, n$  ;  $y =$  **call**  $p, n$  ; **return**  $y$ )
8. Instruções com arrays (i.e. o operador é os parêntesis rectos, e um dos operandos é o índice inteiro).
9. Instruções com ponteiros para memória (como em C)

### 3.4 Controlo de fluxo

- As instruções de controlo de fluxo são as instruções condicionais e os ciclos.
- Em linguagens de baixo nível muitas vezes estas instruções não existem.
- O que existe em alternativa é a possibilidade de dar “saltos” dentro do código recorrendo a endereços (*labels*) e a instruções de salto (*goto*, ...).

```
if (cond) {
    A;
}
else {
    B;
}
```

```
ifFalse cond goto 11
A
goto 12
label 11 :
B
label 12 :
```

- De forma similar podemos gerar código para ciclos:

```
while (cond) {
    A;
}
```

```
label 11 :
ifFalse cond goto 12
A
goto 11
label 12 :
```

### 3.5 Funções

- A geração de código para funções pode ser feita recorrendo a uma estratégia tipo “macro” (i.e. na invocação da funções é colocado o código que implementa a função), ou implementando módulos algorítmicos separados.
- Neste último caso (que, entre outras coisas, permite a recursividade), é necessária a definição de um bloco algorítmico separado, assim como implementar a passagem de argumentos/resultados para/de a função.
- A passagem de argumentos pode seguir diferentes estratégias: passagem por valor, passagem por referência de variáveis, passagem por referência de objectos/registos.
- Para termos implementações recursivas é necessário que se definam novas variáveis em cada invocação da função.
- A estrutura de dados que nos permite fazer isso de uma forma muito eficiente e simples é a pilha de execução.
- Esta pilha armazena os argumentos, variáveis locais à função e o resultado da função (permitindo ao código que invoca a função não só passar os argumentos à função como ir buscar o seu resultado).
- Geralmente as arquitecturas de linguagens de baixo nível (CPU's) têm instruções específicas para lidar com esta estrutura de dados.
- Vamos exemplificar esse procedimento: Este código apenas ilustra a ideia. Para uma análise mais detalhada devem consultar a temática de arquitectura de computadores *frame-pointer*.



```
// use:
... f(x,y);
...
// define:
int f(int a, int b) {
    A;
    return r;
}
```

```
// use:
push 0 // result
push x
push y
call f,2
pop r // result
...
// define:
label f:
pop b
pop a
pop r
store stack-position
A
// reset stack to stack-position
restore stack-position
push r
return
```

